



GRUPO 01

RAG SOBRE PDF

Bruno Saint Clair Silva Oliveira
Gabriel Bastos Pimentel
João Victor Oliveira Moura
José Cerqueira da Silva Neto
Leonardo de Souza Aragão
Marcus Antônio Martins Oliveira Júnior
Yan Victor Araujo do Nascimento

TRILHA C

RAG SOBRE PDF

OLLAMA + OLLAMA_PDF_RAG

repositório de origem:
https://github.com/tonykipkemboi/ollama_pdf_rag

PDF Chat with Ollama

Use the  button below to upload PDFs and ask questions

Your uploaded PDFs appear in the sidebar. Click the sidebar icon to view and manage them.

Summarize the main points from the uploaded PDF

What are the key findings in this document?

Extract important dates and numbers from the PDF

Compare the arguments presented in the document

Send a message...

Documents (1/1) None

 Introduction to the Desi...
590 chunks • 593 pages

Today

Quais os principais tópicos d... ⋮

You have reached the end of your chat history.

Quais os principais tópicos do PDF



⌚ 4s ^

 Searching across 1 PDF(s): Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf  Using model: hf.co/LiquidAI/LFM2.5-2.6B-GGUF:Q4_0  Generating alternative search queries...  Retrieving from: Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf  Found 3 relevant chunks in Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf  Total chunks retrieved: 3  Using top 3 chunks for context  Generating answer with source citations...  Answer generated successfully!

Os principais tópicos do PDF "Introduction to the Design and Analysis of Algorithms" são:

- **Análise e design de algoritmos:** O livro aborda a fundamentação teórica e prática do design e análise de algoritmos, com ênfase em métodos clássicos como *decrease-and-conquer* e *divide-and-conquer* (fonte: [Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf]).
- **Programação dinâmica:** O capítulo 8 é reestruturado para incluir novos materiais introdutórios e exercícios focados em aplicações da programação dinâmica (fonte: [Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf]).
- **Aplicações de algoritmos:** Há uma maior cobertura das aplicações práticas dos algoritmos discutidos (fonte: [Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf]).
- **Algoritmos específicos:** O texto menciona a inclusão de algoritmos como o particionamento de Lomuto e os algoritmos de código Gray (fonte: [Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf]).
- **Exercícios e problemas:** Foram adicionados setenta novos problemas ao final dos capítulos, incluindo desafios algorítmicos e questões de entrevistas de emprego (fonte: [Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf]).

Essas informações são extraídas da descrição da edição atualizada do livro, que destaca as mudanças estruturais e o conteúdo atualizado.

Sources:

- Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf (chunk 517)
- Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf (chunk 16)
- Introduction to the Design and Analysis of Algorithms - FTP Directory (PDFDrive.com).pdf (chunk 525)

MODELOS ESCOLHIDOS

- **Modelo principal: LFM2.5-2.6B**, com 2.6bi de parâmetros.
 - Janela de contexto: até 131.072 tokens (128K).
- **Modelo auxiliar: nomic-embed-text**, com 137mi de parâmetros.

This screenshot shows the Hugging Face model card for LiquidAI/LFM2.5-2.6B. The card features a dark theme with a pink gradient header. It includes a 'Like' button with 757 likes, a 'Follow' button, and a 'Liquid AI' profile link with 5.46k followers. The model is categorized under 'Text Generation', 'Transformers', 'Safetensors', and '16 languages'. It also lists 'lrm2', 'liquid', 'lrm2.5', and 'edge' as related models. The card includes a 'conversational' tag, 'Eval Results', 'arxiv:2511.23404', and 'License: lfm1.0'. Action buttons for 'Deploy', 'Copy to bucket', and 'Use this model' are present. The 'Model card' tab is selected, showing a 'Files' section with a 'xet' icon and a 'Community' section with 20 members. A large pink banner with the 'Liquid' logo is displayed, with links to 'Try LFM', 'Docs', 'LEAP', and 'Discord'. The model name 'LFM2.5-2.6B' is shown at the bottom. On the right, a 'Downloads last month' graph shows 102,206 downloads. The 'Safetensors' section indicates a 'Model size' of '3B params' and a 'Tensor type' of 'BF16', with a 'Chat template' link.

This screenshot shows the Hugging Face model card for nomic-ai/nomic-embed-text-v1.5. The card features a dark theme with a dark blue header. It includes a 'Like' button with 917 likes, a 'Follow' button, and a 'Nomic AI' profile link with 1.23k followers. The model is categorized under 'Sentence Similarity', 'sentence-transformers', 'ONNX', 'Safetensors', and 'Transformers'. It also lists 'Transformers.js', 'English', 'nomic_bert', 'feature-extraction', 'mteb', and 'custom_code' as related models. The card includes 'Eval Results (legacy)', 'Eval Results', 'text-embeddings-inference', and 'arxiv:2402.01613'. Action buttons for 'Deploy', 'Copy to bucket', and 'Use this model' are present. The 'Model card' tab is selected, showing a 'Files' section with a 'xet' icon and a 'Community' section with 62 members. A large dark blue banner with the text 'nomic-embed-text-v1.5: Resizable Production Embeddings with Matryoshka Representation Learning' is displayed, with links to 'Blog', 'Technical Report', 'AWS SageMaker', and 'Nomic Platform'. On the right, a 'Downloads last month' graph shows 15,683,965 downloads. The 'Safetensors' section indicates a 'Model size' of '0.1B params'.

AMBIENTE E RECURSOS

- **Dispositivo:** Notebook Acer Nitro ANV15-51.
- **Processador:** 13th Gen Intel i5-13420H
- **Memória RAM:** 23Gb total, ~12Gb disponíveis para uso.
- **GPU:** NVIDIA GeForce RTX 3050 6Gb.
- **Armazenamento:** SSD NVMe de 512 GB (5,3GB livres).
- **Sistema Operacional:** Ubuntu 24.04.3 LTS (Noble Numbat).
- **Ambiente de execução:**
 - Ollama – v0.32.0,
 - Python – 3.12.3,
 - Node.js – v22.18.0,
 - pnpm – 10.12.2


CAMADAS DE APLICAÇÃO

- **Backend** API desenvolvida em Python 3.12.3 com o framework FastAPI, na porta TCP `8001`.
- **Frontend** Interface gráfica desenvolvida em Next.js 16.0.10 (Node.js v22.18.0, pnpm 10.12.2, Turbopack, React 19), na porta TCP `3000`.
- **Banco de Dados** ChromaDB e SQLite para metadados, armazenados no diretório `data/`.
- **Servidor de Inferência** Ollama v0.32.0, executando como serviço do sistema (`ollama.service`) na porta TCP `11434`.



ARQUITETURA DO SISTEMA

Os componentes utilizam chamadas HTTP REST como mecanismo de comunicação sobre a interface de rede loopback garantindo isolamento dos processos e tolerância a falhas



INICIALIZAÇÃO

1

Execução do script orquestrador './start_all.sh', que dispara simultaneamente o backend FastAPI (porta 8001) e o frontend Next.js (porta 3000).

3

Os vetores de 768 dimensões e seus metadados são gravados nas coleções do ChromaDB no diretório 'data/vectors/'.

2

O usuário envia um documento PDF pela interface web. O backend realiza a extração do texto (pdfplumber), divide o conteúdo em pedaços (chunks) e gera os vetores via modelo nomic-embed-text.

4

Ao receber uma pergunta no chat, a aplicação converte a pergunta em vetor, recupera os 4 trechos mais relevantes do PDF no ChromaDB, monta o prompt contextualizado e envia via streaming SSE para o modelo LFM2.5-2.6B no Ollama.

MAPEAMENTO DE **PROCESSOS**

Como eles se conversam

ENTRADA WEB —→ **BUSCA DE DADOS** —→ **ENVIO AO OLLAMA** —→ **INFERÊNCIA DA GPU**

Do lado do sistema, o Linux gerencia o **ollama serve** e cria o filho **ollama server** para controlar a GPU

Do lado da aplicação, o terminal dispara para o backend **python3** e a interface **next-server**

Porta **3000**: Interface Gráfica
Porta **8001**: Backend FastAPI
Porta **11434**: Ollama requisições

ANÁLISE DE **THREADS**

**172 A 208
THREADS
ATIVAS**

- **51 Threads no Python** executando a busca no banco vetorial ChromaDB e processamento de arquivos
- **25 Threads no Next.js** mantendo a tela do chat interativa no navegador
- **19 Threads por llama-server** alimentando a GPU RTX 3050 com tensores e tratando eventos CUDA
- **20 Threads no Ollama** gerenciando a fila de chegada de requisições.

CHAMADAS DO **SISTEMA**

A análise de **16.031** chamadas de sistema no arquivo **'strace-resumo.txt'**

- **Sincronização de Processos**

'sched_yield'(8.356 chamadas)
'futex'(60 chamadas)
'clone3'(11 chamadas)
'execve'(1 chamada)

- **Arquivos e Documentos**

'openat'(592 chamadas)
'lseek'(872 chamadas)
'read'(954 chamadas)
'newfstatat'(2.001 chamadas)

- **Memória Virtual**

'mmap'(393 chamadas)
'mprotect'(81 chamadas)
'brk'(80 chamadas)

- **Rede IPC**

'socket'(5 chamadas)
'connect'(4 chamadas)
'sendto'(3 chamadas)
'recvfrom'(2 chamadas)


MÉTRICAS DOS RESULTADOS

- Métricas da Execução Padrão
(Configuração 1 - Baseline)

1- **Cold Start do Modelo:** Tempo de carga dos tensores na VRAM = **3,9461 s** | Tempo até a 1ª resposta = **4,6821 s**.

2- **Pergunta Curta** (40 caracteres):Tempo médio RAG total = **47,35 s** | Vazão Ollama = **63,29 tokens/s** | Alocação VRAM = **2.212 MiB**.

3- **Pergunta Longa** (301 caracteres): Tempo médio RAG total = **60,50 s** | Vazão Ollama = **63,94 tokens/s** | Alocação VRAM = **2.212 MiB**.



COMPARAÇÕES ENTRE CONFIGURAÇÕES

Métrica Avaliada	C1 - Baseline	C2 - Concorrência N=4	C3 - Contexto 8192
Tempo Médio por Requisição	47,35s (curta) / 60,50s (longa)	137,44s (curta) / 204,49s (longa)	58,89s (curta) / 72,53s (longa)
Fator de Degradação	1,0x (Baseline)	3,73x (curta) /3,74 (longa	1,19x (+18,8% a +19,5%)
Vazão Média Ollama	~63,5 tokens/s	~61 tokens/s	~62,9 tokens/s
Alocação de VRAM GPU	2.212 MB	2.248 MB (+36 MB)	2.354 MB (+142 MB)
Memória RAM Física(Host)	~12,8 GB	~14,5 GB (+1,7 GB)	~14,3 GB (+1,1 GB)
RSS Processo ‘llama-server’	1,24 GB	2,97GB (+139%)	1,48 GB
Taxa de Sucesso/Falhas	100% Sucesso (0 erros)	91,7% Sucesso (1 Timeout 300s)	100% Sucesso (0 erros)



RISCOS **LIMITAÇÕES**

**GARGALO DE
VRAM DA GPU**


**RESTRIÇÃO DE
ARMAZENAMENTO**

**ARQUITETURA DE
CPU HETEROGÊNEA**

**SERIALIZAÇÃO NO
DISPOSITIVO GPU**

EXECUÇÃO LOCAL DE IA GENERATIVA

- **Privacidade e Autonomia Total:** O processamento ocorre 100% isolado na infraestrutura local via sockets de loopback (`127.0.0.1`), sem tráfego de dados confidenciais para APIs externas ou custos por token.
- **Gestão Heterogênea de Memória pelo SO:** A inferência local exige a cooperação entre o driver da GPU e o kernel Linux: o modelo é alocado na VRAM, enquanto o contexto expandido de múltiplos usuários faz o sistema utilizar a memória RAM principal como buffer estendido (+139% de RSS).
- **Eficiência via Primitivas de SO:** A utilização de `mmap` para leitura de pesos GGUF, `io\_uring` para I/O síncrono/assíncrono veloz e o escalonador EEVDF do Linux garantem que a inferência atinja ****63 tok/s**** sem travar o sistema.





OBRIGADO!